

*Institut Supérieur d'Informatique et des Mathématiques de Monastir*



# **TECHNIQUES D'INDEXATION ET RECHERCHE MULTIMÉDIA**

**IMEN CHEBBI**

# Chapitre 2

## 1. Indexation

## **Recherche d'information (RI) :**

**Ensemble des méthodes et techniques pour l'acquisition, l'organisation, le stockage, la recherche et la sélection d'information pertinente pour un utilisateur**



## Un Système de Recherche d'Information (SRI)

Un système de recherche d'information (RI) est un système qui permet de retrouver les documents pertinents à une requête d'utilisateur, à partir d'une base de documents volumineuse.

Trois notions clés: **documents, requête, pertinence.**



**Requête** : exprime le besoin d'information d'un utilisateur

**Document** : toute unité qui peut constituer une réponse à une requête,

Un document peut être un texte, un morceau de texte, une page Web, une image, une bande vidéo, etc,

**Base de documents** : ensemble des documents disponibles

**Pertinence** : De façon générale, dans document pertinent, l'utilisateur doit pouvoir trouver les informations dont il a besoin. Sur cette notion le système doit juger si un document doit être donné à l'utilisateur comme réponse ou non

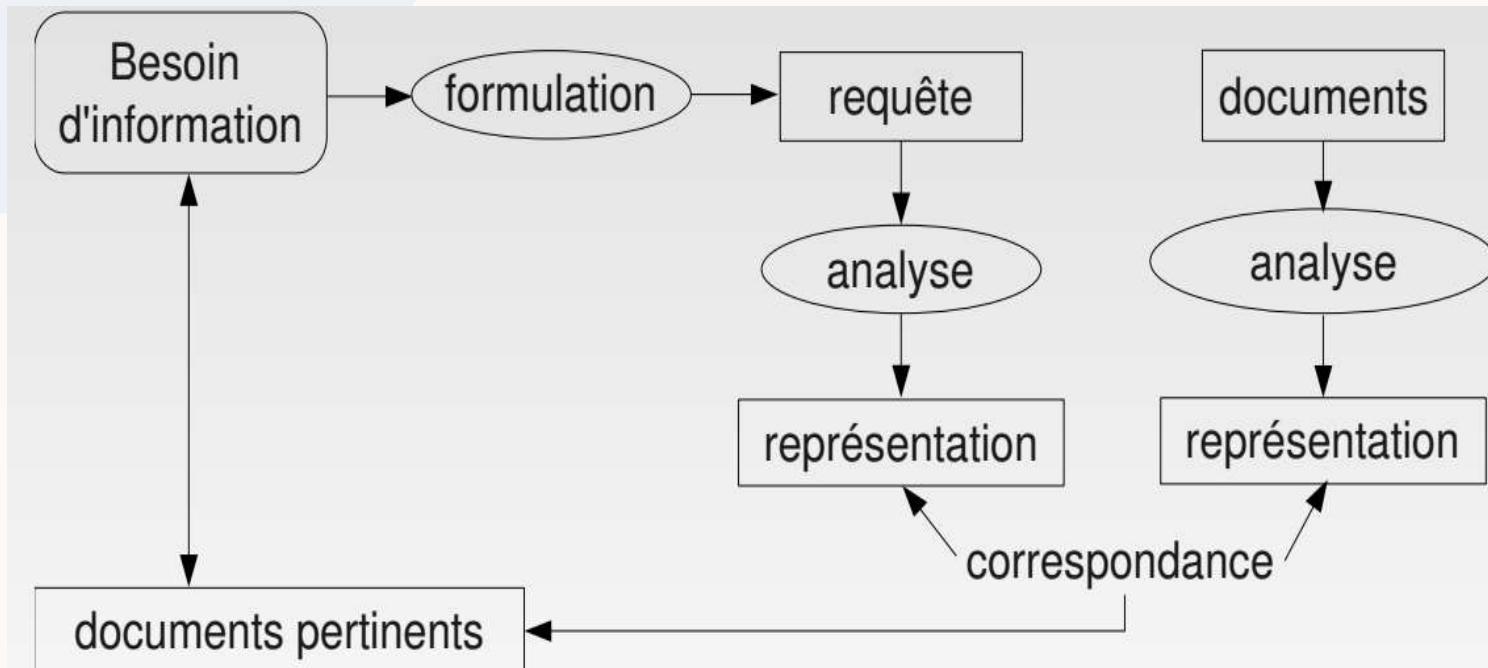


# EXEMPLES D'APPLICATIONS

- Outils de recherche dans les mails, dans les fichiers,  
...  
• Systèmes de RI documentaires,
- Systèmes de RI pour les bases de documents d'une entreprise,
- Systèmes de RI sur le Web tels que google, bing  
,,,etc.

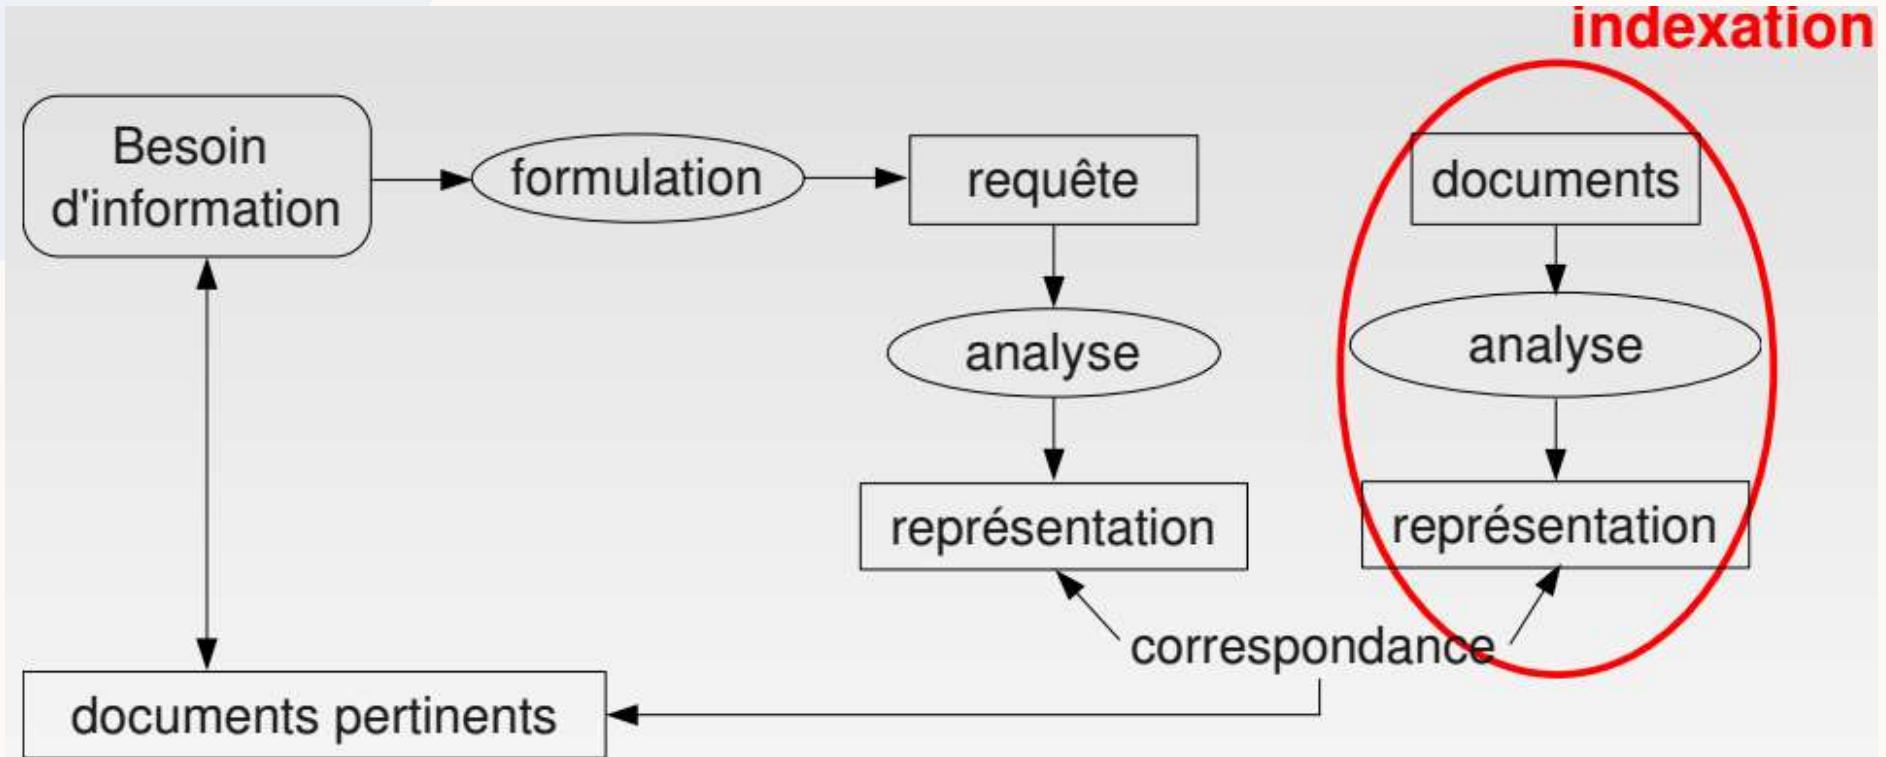


# APPROCHE CLASSIQUE DE LA RI

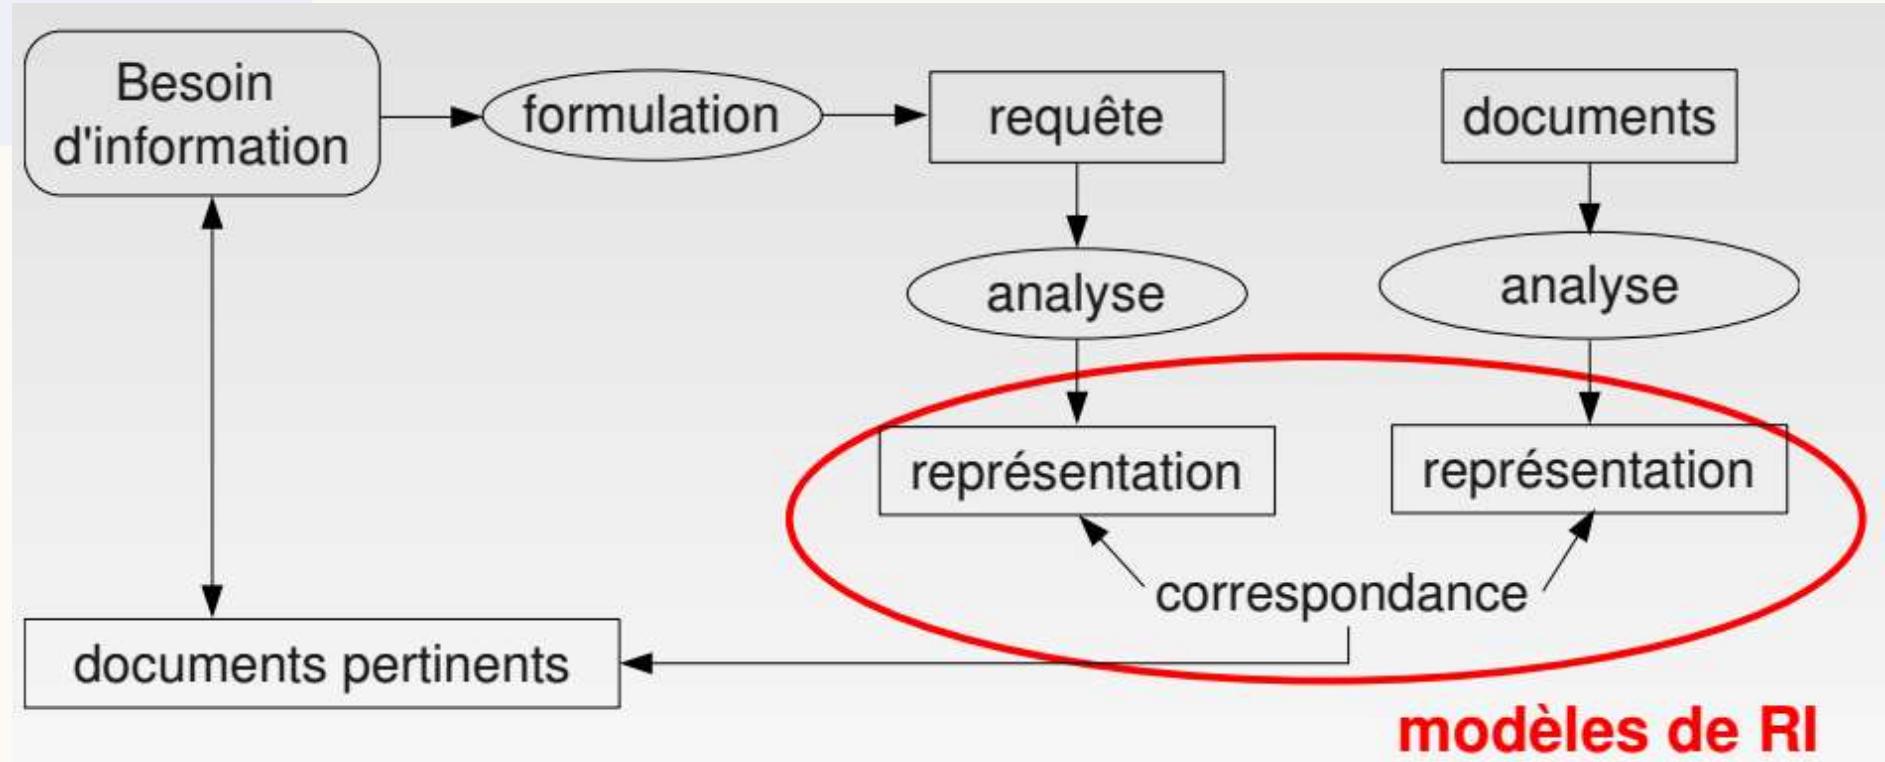


# APPROCHE CLASSIQUE DE LA RI

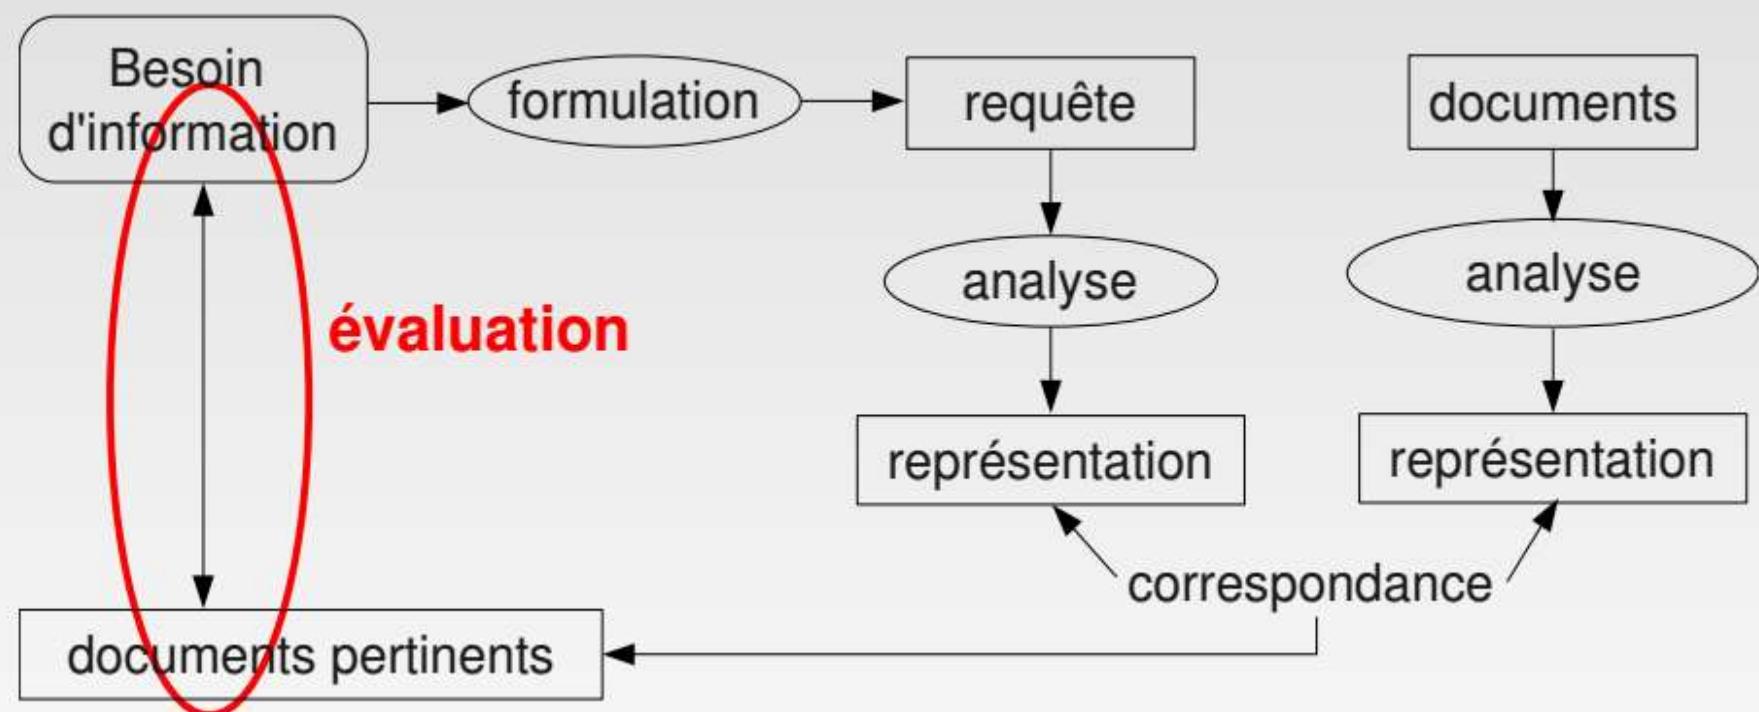
8



# APPROCHE CLASSIQUE DE LA RI



# APPROCHE CLASSIQUE DE LA RI



# INDEXATION

base  
de  
données

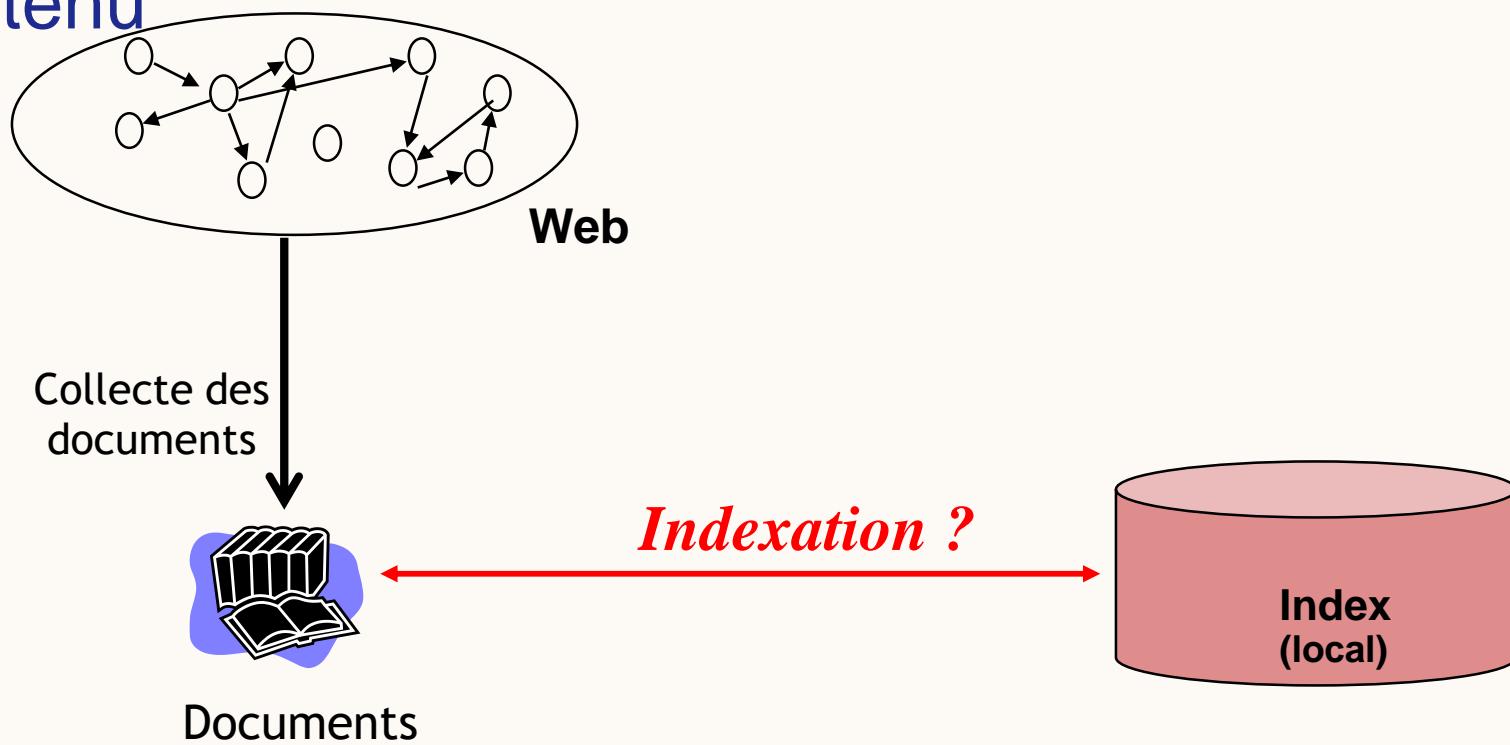
# INDEXATION - POURQUOI UTILISER LES INDEX ?

- Imaginez un moteur de recherche qui ne dispose pas d'une base d'index
- Pour chaque requête, il doit
  - accéder au Web (faire un tour complet)
  - analyser les documents un par un
  - juger l'importance de chaque document par rapport à la requête en question
  - « fabriquer» la réponse en fonction des pertinences des documents
  - afficher le résultat

=> une base d'index est indispensable

# INDEXATION

- Analyse du document et interprétation de son contenu



# INDEXATION



- Un index contient une "interprétation" du document au lieu du document entier
- Il contient
  - les termes représentatifs d'un document
  - les poids (l'importance) des termes dans chaque document
- Chaque moteur possède un index inverse
  - transformation de  
**"quels mots apparaissent dans la page ?"** en **"dans quelles pages (URL) apparaît le mot X?"**

# INDEXATION

- Peut être
  - Manuelle (expert en indexation)
  - Automatique (ordinateur)
  - Semi-automatique (combinaison des deux)
- Basée sur
  - Un langage contrôlé  
(lexique/thesaurus/ontologie/réseau sémantique)
  - Un langage libre (éléments pris directement des documents)



# INDEXATION MANUELLE

- Choix des mots effectué par des indexeurs
- Basée sur un vocabulaire contrôlé
- Approche utilisée souvent dans les bibliothèques, les centres de documentation
- Dépend du savoir faire de l'indexeur

## **INDEXATION MANUELLE: AVANTAGE DU VOCABULAIRE CONTRÔLE**

- Permet la recherche par concepts (par sujets, par thèmes), plus intéressante que la recherche par mots simples.
- Permet la classification (regroupement) de documents (par sujets, par thème).
- Fournit une terminologie standard pour indexer et rechercher les documents

# INDEXATION MANUELLE: INCOVÉNIENT DU VOCABULAIRE CONTRÔLE

## Indexation très coûteuse

- Pour construire le vocabulaire
- Pour affecter les concepts (termes) aux documents (**imaginer cette opération sur le web**)

## Difficile à maintenir

- La terminologie évolue, plusieurs termes sont rajoutés tous les jours

Processus humain donc subjectif

- Des termes différents peuvent être affectés à un même document par des indexeurs différents

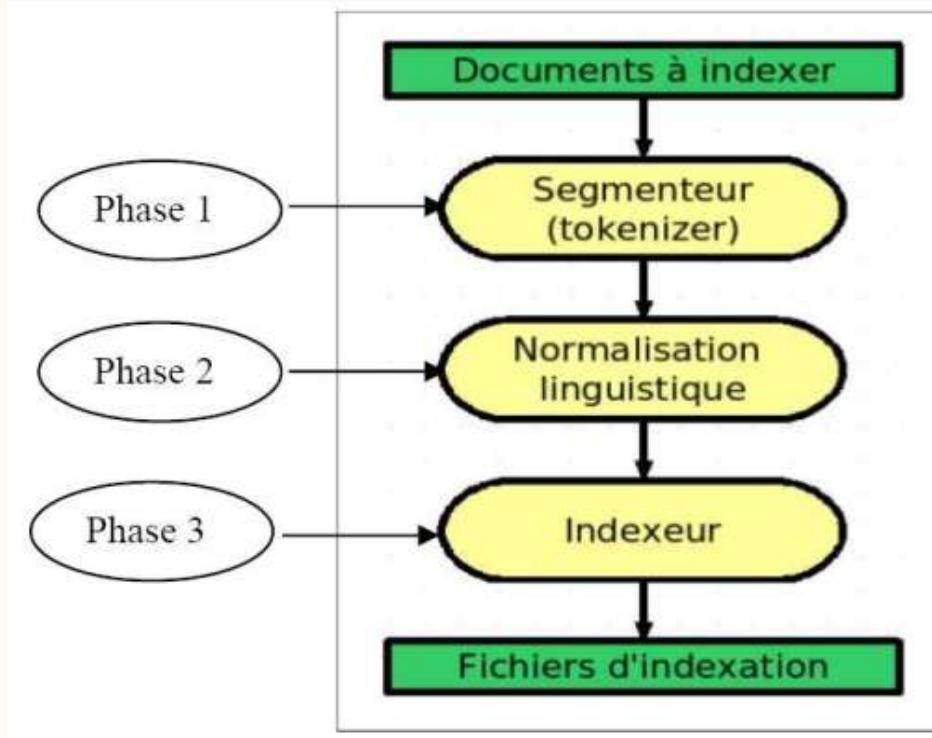
Les utilisateurs ne connaissent pas forcément le vocabulaire utilisé par les indexeurs

# INDEXATION AUTOMATIQUE

- **Approches basées sur**
  - Statistique (distribution des mots) et/ou TALN (compréhension du texte)
- **Approche repose sur des hypothèses simples:**
  - Redondance d'un mot marque son importance
  - Cooccurrence des mots marque le sujet d'un document

# INDEXATION AUTOMATIQUE: PROCESSUS

- Le processus de l'indexation se constitue de :



# INDEXATION AUTOMATIQUE

## ETAPE 1 : EXTRACTION DES MOTS

- Extraire les termes (tokenization)
  - terme = suite de caractères séparés par (blanc ou signe de ponctuation, caractères spéciaux,...), Nombres
- Ce sont les index utilisés lors de la recherche
- Dépend de la langue

# INDEXATION AUTOMATIQUE

## ETAPE 2 : NORMALISATION

- Cette phase peut contenir plusieurs étapes.
- Les étapes les plus importantes et les plus utilisées :
  1. *Elimination des mots vides*
  2. *La racinisation* (« stemming » en anglais)
  3. *La lemmatisation*
  4. *Extraction des mots composés*
  5. *Extraction des entités nommées,*

# NORMALISATION: ELIMINATION DES MOTS VIDES

- Les mots vides (article, proposition, conjonction, etc.) sont des mots non significatifs dans un document, car ils ne traitent pas le sujet du document.
- On distingue deux techniques pour éliminer les mots vides :
  - L'utilisation d'une liste préétablie de mots vides (*stop-words*),
  - L'élimination des mots ayant une fréquence qui dépasse un certain seuil dans la collection.
- L'élimination des mots vides réduit la taille de l'index, ce qui améliore le temps de réponse du système.

# NORMALISATION: STEMMING

- La normalisation consiste à représenter les différentes variantes d'un terme par un format unique appelé lemme ou racine. Ce qui a pour effet de réduire la taille de l'index.
- Plusieurs stratégies de normalisation sont utilisées :
  - la table de correspondance,
  - l'élimination des affixes (**l'algorithme de Porter**),
  - la troncature,
  - l'utilisation des N-grammes.

# NORMALISATION: STEMMING

- Exemple:

PRÉFIXE	RADICAL	Suffixe
Pré	traite	ment

- économie, économiquement, économiste, → économ
- pour l'anglais : retrieve, retrieving, retrieval, retrieved, retrieves  
→ retriev
- L'inconvénient majeur de cette opération est qu'elle supprime dans certains cas la sémantique des termes originaux,

# INDEXATION AUTOMATIQUE: INDEX INVERSE

- Une fois les documents indexés :
  - chaque document aura donc un descripteur (une liste de mots souvent simples): à Sac de mots (Bag of Words)
  - Ces termes sont ensuite stockés dans une structure appelée fichier inverse.

# INDEXATION AUTOMATIQUE: INDEX INVERSE

- Dans sa forme la plus simple, l'index inversé d'une collection de documents est essentiellement une structure de données qui relie chaque terme distinct à une liste de tous les documents qui le contiennent.

## INDEX INVERSÉ

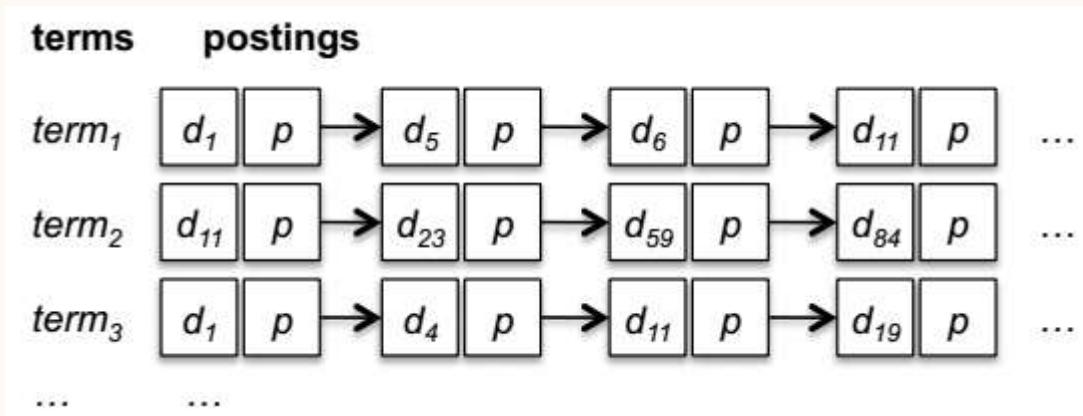
- Un index inversé se compose de deux parties:
  1. Un vocabulaire V, contenant tous les termes distincts de l'ensemble de documents, et
  2. pour chaque terme distinct, une liste inversée de publications.

## INDEX INVERSE

- Chaque enregistrement stocke l'ID (désigné par  $id_j$ ) du document  $d_j$  qui contient le terme  $t_i$  et d'autres informations sur ce terme dans ce document.
- Selon le besoin de l'algorithme de recherche ou de classement, différentes informations peuvent être incluses.

# INDEX INVERSÉ

- Pour chaque terme, nous avons une liste qui enregistre dans quels documents le terme se produit.
- Chaque terme de la liste est appelé classiquement **Posting** (publication).
- Un Posting est un tuple de la forme  $(t_i, d_j)$ , où  $t_i$  est un identificateur de terme et  $d_j$  est un identifiant de document.
- La liste est appelée liste de posting (ou liste inversée)



# INDEX INVERSÉ

- Les index inversés sont indépendants du modèle IR adopté (Modèle booléen, modèle d'espace vectoriel, etc.)
- Chaque Posting contient généralement:
  - L'identifiant du document lié.
  - La fréquence d'apparition du terme dans le document
  - La position du terme pour chaque document (facultatif)
    - Exprimé en nombre de mots depuis le début du document, le nombre d'octets, etc.
- Pour chaque terme est également généralement stocké la fréquence d'apparition du terme dans l'ensemble des documents.

# INDEX INVERSE: CONSTRUCTION

- Extraire les termes de chaque document dans un fichier (1 fichier par document) ou un fichier pour plusieurs documents)

Doc 1

I did enact Julius  
Caesar I was killed  
i' the Capitol;  
Brutus killed me.

Doc 2

So let it be with  
Caesar. The noble  
Brutus hath told you  
Caesar was ambitious



Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

# INDEX INVERSÉ: CONSTRUCTION

- Trier le fichier termes-documents:  
Trier le fichier par ordre alphabétique des termes et par document

Term	Doc #
I	1
did	1
enact	1
julius	1
caesar	1
I	1
was	1
killed	1
i'	1
the	1
capitol	1
brutus	1
killed	1
me	1
so	2
let	2
it	2
be	2
with	2
caesar	2
the	2
noble	2
brutus	2
hath	2
told	2
you	2
caesar	2
was	2
ambitious	2

Term	Doc #
ambitious	2
be	2
brutus	1
brutus	2
capitol	1
caesar	1
caesar	2
caesar	2
did	1
enact	1
hath	1
I	1
I	1
i'	1
it	2
julius	1
killed	1
killed	1
let	2
me	1
noble	2
so	2
the	1
the	2
told	2
you	2
was	1
was	2
with	2



# INDEX INVERSÉ: CONSTRUCTION

- Pour chaque terme,
  - on dispose de la liste de documents qui le contient
  - Le nombre de documents comportant ce terme

Term	Doc #
ambitious	2
be	2
brutus	1
brutus	2
capitol	1
caesar	1
caesar	2
caesar	2
did	1
enact	1
hath	1
I	1
I	1
i'	1
it	2
julius	1
killed	1
killed	1
let	2
me	1
noble	2
so	2
the	1
the	2
told	2
you	2
was	1
was	2
with	2



Term	Doc #	Freq
ambitious	2	1
be	2	1
brutus	1	1
brutus	2	1
capitol	1	1
caesar	1	1
caesar	2	2
did	1	1
enact	1	1
hath	2	1
I	1	2
i'	1	1
it	2	1
julius	1	1
killed	1	2
let	2	1
me	1	1
noble	2	1
so	2	1
the	1	1
the	2	1
told	2	1
you	2	1
was	1	1
was	2	1
with	2	1

# INDEX INVERSÉ: CONSTRUCTION

Term	Doc #	Freq
ambitious	2	1
be	2	1
brutus	1	1
brutus	2	1
capitol	1	1
caesar	1	1
caesar	2	2
did	1	1
enact	1	1
hath	2	1
I	1	2
i'	1	1
it	2	1
julius	1	1
killed	1	2
let	2	1
me	1	1
noble	2	1
so	2	1
the	1	1
the	2	1
told	2	1
you	2	1
was	1	1
was	2	1
with	2	1



Term	N docs	Tot Freq
ambitious	1	1
be	1	1
brutus	2	2
capitol	1	1
caesar	2	3
did	1	1
enact	1	1
hath	1	1
I	1	2
i'	1	1
it	1	1
julius	1	1
killed	1	2
let	1	1
me	1	1
noble	1	1
so	1	1
the	2	2
told	1	1
you	1	1
was	2	2
with	1	1

Doc #	Freq
2	1
2	1
1	1
2	1
1	1
1	1
2	2
1	1
1	1
2	1
1	2
1	1
2	1
1	1
2	1
1	1
2	1
1	1
2	1
2	1
2	1
1	1
2	1
2	1
1	1
2	1
2	1

# INDEX INVERSÉ: ORGANISATION

Dictionnaire

Mot	Nb Doc	Frq Tota	Ptr
Ambitious	2	6	1
Brutus	2	4	3
capitol	5	15	6

*Posting simple*

doc	Freq
doc1	3
doc2	2
doc1	1
doc3	7



- Liste triée
- B-Arbre
- Table de hashage (hash-code)
- ...

Position du terme dans le document  
(important pour la recherche d'expressions)

*Posting riche*

doc	Freq	position	balise
doc1	3	1, 4, 3	1, 5
doc2	2	1	
doc3	2	3	
	0	0	

Balises (title,  
body,  
anchor, ...)

# INDEX INVERSÉ: STOCKAGE

**Les termes se trouvent généralement dans un certain nombre de documents:**

- Les index inversés réduisent les besoins de stockage de l'index,
- fournir la base pour une recherche efficace
- cette structure d'index inversé est essentiellement sans rivaux comme la structure la plus efficace pour supporter la recherche de texte.

# INDEX INVERSÉ: STOCKAGE

38

**Les listes liées généralement préférées aux tableaux:**

- Allocation dynamique de l'espace
- L'insertion de termes dans les documents est facile
- Frais généraux des pointeurs
- Espace requis

# INDEXATION DISTRIBUÉE

Pour de très larges collections (Web).

Un serveur principal dirige le tout

- Il divise la tâche d'indexation en un ensemble de tâches parallèles
- Il assigne chaque tâche à une machine libre et fonctionnelle du réseau

**MERCI**